



ČVUT
ČESKÉ VYSOKÉ
UČENÍ TECHNICKÉ
V PRAZE

TRANSFER LEARNING FOR CLOUD SEMANTIC SEGMENTATION ON SATELLITE IMAGERY

PŘENOSOVÉ UČENÍ PRO SEMANTICKOU SEGMENTACI OBLAKŮ NA SATELITNÍCH SNÍMCÍCH

OBOR: GEODÉZIE A KARTOGRAFIE
SPECIALIZACE: GEOMATIKA

AUTOR: Bc. MATĚJ KLIMEŠ
VEDOUCÍ: Ing. ONDŘEJ PEŠEK, Ph.D.

ÚVOD

Dvě třetiny zemského povrchu jsou pokryty oblaky

Detekce oblaků je stěžejní krok zpracování optických satelitních snímků

Modely hlubokého učení jsou citlivé na změnu senzoru


Adaptace na nový senzor typicky vyžaduje nová anotovaná data

Přenosové učení nabízí řešení



PŘENOSOVÉ UČENÍ

- Využití znalostí z jedné úlohy k řešení úlohy jiné
- Předpoklad podobnosti
- Zdroj - Sentinel-2
- Cíl - VEN μ S



VÝZKUMNÉ OTÁZKY

- 1** Dokáže se model trénovaný na datech Sentinel-2 generalizovat na data VEN μ S při použití selekce spektrálních pásem jako základní doménové adaptace, a jaký vliv má radiometrická normalizace vstupních dat?
- 2** Jaký rozsah adaptace předtrénované sítě je nezbytný pro efektivní přenos mezi senzory a překonává adaptace celé sítě částečné adaptační strategie?
- 3** Může přenosové učení z dat Sentinel-2 dosáhnout srovnatelného výkonu jako model trénovaný od začátku na datech VEN μ S, a pokud ano, jaká míra adaptace je k tomu nutná?



DATA

Sentinel-2

- Globální pokrytí
- 13 spektrálních pásem
- Prostorové rozlišení 10 až 60 m

VEN μ S

- Regionální pokrytí
- 12 spektrálních pásem
- Prostorové rozlišení 5 nebo 10 m




CloudSEN12+ dataset

- Největší veřejně dostupný dataset
- 4 třídy: oblak (tenký/silný), stín, čirý pixel
- Rozlišení 10 m
- Level 1 produkt

VEN μ S dataset

- Dataset z oblasti Izraele (Negevská poušť)
- 3 třídy: oblak (tenký/silný), bezoblačno
- Rozlišení 10 a 5 m
- Level 2 produkt

METODOLOGIE



Společné kroky

- Výběr ekvivalentních pásem
- Sloučení tříd oblaků
- Generování datasetu
- Normalizace dat

Specifické kroky

- Sentinel-2 – filtrace datasetu
- VEN μ S - NODATA

Společné kroky

- Výběr ekvivalentních pásem
- Sloučení tříd oblaků
- Generování datasetu
- Normalizace dat

Specifické kroky

- Sentinel-2 – filtrace datasetu
- VEN μ S - NODATA

VEN μ S	λ (nm)	Sentinel-2	λ (nm)	$\Delta\lambda$ (nm)	Description
B3	491.9	B2	490	1.9	Blue
B4	555.0	B3	560	5.0	Green
B7	666.2	B4	665	1.2	Red
B8	702.0	B5	705	3.0	Red-edge 1
B9	741.1	B6	740	1.1	Red-edge 2
B10	782.2	B7	783	0.8	Red-edge 3
B11	861.1	B8A	865	3.9	Narrow NIR

λ denotes the central wavelength.

$\Delta\lambda$ denotes the absolute difference in central wavelength between sensors.

Společné kroky

- Výběr ekvivalentních pásem
- Sloučení tříd oblaků
- Generování datasetu →
- Normalizace dat

	Sentinel-2	VEN _μ S
After geographic filtering	269	—
Excluded during quality review	129	—
Available after filtering	140	135
Test set	10	10
Training set	98	93
Validation set	32	32
Training set (augmented)	392	372

Specifické kroky

- Sentinel-2 – filtrace datasetu
- VEN_μS - NODATA

Společné kroky

- Výběr ekvivalentních pásem
- Sloučení tříd oblaků
- Generování datasetu
- Normalizace dat

Strategy	Statistics source	Applied to	Scope
Raw	—	S2, VEN μ S	—
Fixed Z-score (S2 statistics)	S2 training set	S2, VEN μ S	Global
Fixed Z-score (VEN μ S statistics)	VEN μ S training set	VEN μ S	Global
Dynamic Z-score	Per tile	S2, VEN μ S	Per tile

Specifické kroky

- Sentinel-2 – filtrace datasetu
- VEN μ S - NODATA


$$\hat{x}_b = \frac{x_b - \mu_b}{\sigma_b}$$

Společné kroky

- Výběr ekvivalentních pásem
- Sloučení tříd oblaků
- Generování datasetu
- Normalizace dat

Specifické kroky

- Sentinel-2 – filtrace datasetu
- VEN μ S - NODATA



Architektura


- U-Net

Vstupní data

- 7 spektrálně ekvivalentních pásem
- dlaždice o velikosti 512×512 px

Výsledek trénování

- 3 modely trénované na datech Sentinel-2
- 3 modely trénované na datech VEN μ S



Transduktivní přenos

- Aplikace Sentinel-2 modelů na VEN μ S data
- Zachovány 3 třídy (oblak, stín, čirý pixel)

Induktivní přenos

- Adaptace modelů pomocí dat VEN μ S
- Výstupní vrstva upravena na 2 třídy (oblak, bezoblačno)
- 3 adaptační strategie

Metriky

- F1, Precision, Recall
- mF1, mIoU, OA, BOA


ID	Name	Setting	Fine-tuned scope	Patience
B1	MAJA	Baseline	—	—
B2	From scratch	Baseline	—	200
E0	Transductive	Transductive	None	—
E1	Output layer	Inductive	Output layer	100
E2	Frozen encoder	Inductive	Decoder + output	100
E3	Full fine-tune	Inductive	Full network	100

All transfer learning experiments use the best Sentinel-2 checkpoint as initialization.
E0 produces 3-class output; all other VEN μ S experiments produce 2-class output.

Experiment	Raw	Fixed (S2)	Fixed (VEN μ S)	Dynamic
B1 (MAJA)	✗	✗	✗	✗
B2 (From scratch)	✓	✗	✓	✓
E0 (Transductive)	✓	✓	✓	✓
E1 (Output layer)	✓	✓	✓	✓
E2 (Frozen encoder)	✓	✓	✓	✓
E3 (Full fine-tune)	✓	✓	✓	✓


VÝSLEDKY EXPERIMENTŮ

Exp.	Best norm.	mF1	mIoU	OA	BOA
B2	Raw	0.954	0.914	0.971	0.945
E0	Dynamic	0.919	0.853	0.943	0.954
E1	Fixed ($\text{VEN}_{\mu\text{S}}$)	0.952	0.910	0.970	0.934
E2	Fixed ($\text{VEN}_{\mu\text{S}}$)	0.961	0.926	0.975	0.952
E3	Dynamic	0.956	0.916	0.972	0.942




VÝSLEDKY EXPERIMENTŮ


Exp.	Best norm.	mF1	mIoU	OA	BOA
B2	Raw	0.954	0.914	0.971	0.945
E0	Dynamic	0.919	0.853	0.943	0.954
E1	Fixed ($\text{VEN}_{\mu\text{S}}$)	0.952	0.910	0.970	0.934
E2	Fixed ($\text{VEN}_{\mu\text{S}}$)	0.961	0.926	0.975	0.952
E3	Dynamic	0.956	0.916	0.972	0.942



VÝSLEDKY EXPERIMENTŮ – E0



VÝSLEDKY EXPERIMENTŮ – E2




VÝZKUMNÉ OTÁZKY

1

Dokáže se model trénovaný na datech Sentinel-2 generalizovat na data VEN μ S při použití selekce spektrálních pásem jako základní doménové adaptace, a jaký vliv má radiometrická normalizace vstupních dat?

- Pouze selekce spektrálních pásem není dostatečná
- Závisí na zvolené normalizační strategii – dynamická je efektivní




VÝZKUMNÉ OTÁZKY

2

Jaký rozsah adaptace předtrénované sítě je nezbytný pro efektivní přenos mezi senzory a překonává adaptace celé sítě částečné adaptační strategie?

- I minimální adaptace je dostatečná
- Nejlepších výsledků dosahuje adaptace se zmrazeným kódem




Exp.	Best norm.	mF1	mIoU	OA	BOA
B2	Raw	0.954	0.914	0.971	0.945
E0	Dynamic	0.919	0.853	0.943	0.954
E1	Fixed (VEN μ S)	0.952	0.910	0.970	0.934
E2	Fixed (VEN μ S)	0.961	0.926	0.975	0.952
E3	Dynamic	0.956	0.916	0.972	0.942



VÝZKUMNÉ OTÁZKY

3 Může přenosové učení z dat Sentinel-2 dosáhnout srovnatelného výkonu jako model trénovaný od začátku na datech VEN μ S, a pokud ano, jaká míra adaptace je k tomu nutná?

- Všechny induktivní experimenty dosáhly srovnatelného výkonu
- E2 a E3 dokonce mírně překonali B2



Exp.	Best norm.	mF1	mIoU	OA	BOA
B2	Raw	0.954	0.914	0.971	0.945
E0	Dynamic	0.919	0.853	0.943	0.954
E1	Fixed (VEN μ S)	0.952	0.910	0.970	0.934
E2	Fixed (VEN μ S)	0.961	0.926	0.975	0.952
E3	Dynamic	0.956	0.916	0.972	0.942

ZÁVĚR


Přenosové učení mezi senzory je efektivní

Při transduktivním přenosu hraje normalizace zásadní roli

Implementace veřejně dostupná na GitHubu

Příspěvky do open-source knihovny

Potenciál aplikace na další satelitní senzory a datasety





ČVUT
ČESKÉ VYSOKÉ
UČENÍ TECHNICKÉ
V PRAZE

DĚKUJI ZA POZORNOST



DALŠÍ VÝSLEDKY - MAJA a S-2




FIGURE 4.5: Comparison of MAJA cloud masks and ground truth annotations for the three VENμS tiles covered in the dataset.




FIGURE 4.2: Representative Sentinel-2 test set predictions using dynamic Z-score normalization.

GEOGRAFICKÁ DISTRIBUCE DAT



FIGURE 3.1: Geographic distribution of CloudSEN12+ patches within the area of interest.





FIGURE 3.2: VEN μ S tile strips over Israel.



NEKVALITNÍ ANOTACE – CSEN12+



PŘÍSPĚVKY DO CNN-LIB

main	klimesm	Dec 5, 2025 - May 17
Commits on May 17, 2026		
Fix: avoid NaN loss when batch contains only ignore-value pixels (#46)	klimesm authored on May 17 · ✓ 2 / 2	1 Verified 403b444
Commits on May 11, 2026		
Fix data leakage between train and val sets (#45)	klimesm authored on May 11 · ✓ 2 / 2	1 Verified 4a8ce72
Commits on May 5, 2026		
Fix Keras compiled metrics API for fine-tune recompilation (#48)	klimesm authored on May 5 · ✓ 2 / 2	1 Verified 28ad175
Commits on Mar 23, 2026		
fix run() label check in detect.py (#40)	klimesm and peskon2 authored on Mar 23 · ✓ 2 / 2	1 Verified 9980dce
add layer freezing and skip_mismatch support for fine-tuning (#39)	klimesm authored on Mar 23 · ✓ 2 / 2	1 Verified 5d82c80
Commits on Mar 22, 2026		
Add padding support (#38)	klimesm authored on Mar 22 · ✓ 2 / 2	1 Verified cf2acea
Commits on Feb 21, 2026		
fix band_nr calculation if train/val data provided (#37)	klimesm authored on Feb 21 · ✓ 2 / 2	1 Verified ee1242b
Commits on Feb 20, 2026		
visualization: fix image display and confusion matrix (#36)	klimesm authored on Feb 20 · ✓ 2 / 2	1 Verified 6d950c0
Commits on Dec 5, 2025		
Fix model name bug (#27)	klimesm authored on Dec 5, 2025 · ✓ 1 / 1	Verified ca3b7b2



KONVOLUCE A MAX POOLING




FIGURE 2.2: Principle of 2D convolution.




FIGURE 2.3: Principle of 2×2 max pooling with stride 2.

METRIKY

Reference label	Cloud	TP	FN	FN
	Clear	FP	TN	TN
	Shadow	FP	TN	TN
		Cloud	Clear	Shadow
		Predicted label		

Highlighted: Cloud class (one-vs-rest)

FIGURE 2.6: Multi-class confusion matrix with one-vs-rest interpretation for the Cloud class.

True label	clear [1281194]	0.95	0.03	0.03
	cloud [955299]	0.11	0.86	0.03
	shadow [354317]	0.10	0.13	0.77
		clear	cloud	shadow
		Predicted label		

FIGURE 4.1: Confusion matrix for the Sentinel-2 model with dynamic Z-score normalization on the Sentinel-2 test set. Values are normalized by row.

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{OA} = \frac{\sum_i CM_{ii}}{\sum_i \sum_j CM_{ij}}$$

$$\text{BOA} = \frac{1}{C} \sum_{c=1}^C \text{Recall}_c$$

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

$$\text{IoU} = \frac{TP}{TP + FP + FN}$$

